MACKENZIE - BANCO DE DADOS - 2026.2

PROJETO APLICADO II

COMPONENTE CURRICULAR:	Banco de Dados - Projeto Aplicado II	
GRUPO Query NOME COMPLETO DOS ALUNOS:	Caio Balista Ferreira Pedretti	RA: 10751989
	Kauan Lima da Silva	RA: 10748047
	Leonardo de Barros Magalhães	RA: 10752304
	Eduardo Pereira Callado Neto	RA: 10750949

A2 - Aplicando Conhecimento - 23/10/2026

Nome da empresa:

Olist Plataforma de Ecommerce

Link para Github:

https://github.com/CaioPedretti/Projeto-Aplicado-II-Grupo-Query

Sumário

Sumário 1
Glossário 2
ENTREGA 1 - KICK-OFF 3
Contexto de estudo e objetivos do trabalho 3
Cronograma 4
Apresentação da empresa: Olist 5
Apresentação dos metadados 6
Projeto de Estudo 7
ENTREGA 2 - MÉTODO ANALÍTICO 9
Refinamento dos Objetivos: Metas Numéricas e KPIs 9
1. Definição da Linguagem de Programação e Ecossistema Tecnológico 10
Ecossistema de Bibliotecas e Justificativa Técnica 10
2. Análise Exploratória de Dados (EDA) 11
3. Tratamento, Preparação e Treinamento da Base de Dados 12
Processo Detalhado de Preparação 12
4. Definição e Descrição das Bases Teóricas dos Métodos 14
Pergunta 1: Logística e Satisfação do Cliente (NPS Implícito) 14
Pergunta 2: Inteligência Geográfica e Impacto do Frete 14
Pergunta 3: Desempenho e Sazonalidade de Vendas 15
5. Definição e Descrição do Cálculo de Acurácia e Avaliação de Desempenho 16
5.1 Métricas para o Modelo de Classificação (Pergunta 1: Satisfação do Cliente) 16
5.2 Métricas para o Modelo de Agrupamento / Clustering (Pergunta 2: Impacto do Frete) 16
5.3 Métricas para o Modelo de Séries Temporais e Regressão (Pergunta 3: Sazonalidade de Vendas) 17

Glossário

Chave Primária (Primary Key): Identificador único e exclusivo para cada registro dentro de uma tabela. No contexto do trabalho, representada por colunas como order_id e customer_id, garantindo a rastreabilidade exata de cada pedido e cliente.

Chave Estrangeira (Foreign Key): Coluna ou grupo de colunas em uma tabela que provê um link para os dados em outra tabela, fundamental para a estrutura relacional do dataset da Olist.

CSV (Comma-Separated Values): Formato de arquivo simples que armazena dados tabulares em texto puro. Formato dos arquivos do dataset.

Dataset: Conjunto de dados estruturados. Refere-se aos arquivos extraídos do Kaggle contendo cerca de 100.000 pedidos reais anonimizados.

E-commerce / Marketplace: Modelo de comércio eletrônico onde a plataforma (neste caso, conectada pela Olist) atua como um shopping virtual, permitindo que vários lojistas vendam seus produtos em um único espaço.

Float: Tipo de dado numérico para valores com casas decimais (ex: price, freight_value).

Kaggle: Plataforma online focada em ciência de dados e machine learning, que hospeda competições e disponibiliza grandes conjuntos de dados (datasets) públicos para estudo e análise.

Metadados: "Dados sobre os dados". São as informações que descrevem a estrutura e o conteúdo do dataset, como o tipo de dado de cada coluna, o que ela significa, seus valores máximos/mínimos e sua codificação.

Timestamp: Tipo de dado utilizado para registrar a data e hora exatas de um evento (ex: order_purchase_timestamp).

UTF-8: Padrão de codificação de caracteres utilizado mundialmente que garante que textos, acentos e símbolos de diversos idiomas sejam interpretados e exibidos corretamente pelo computador.

Varchar: Tipo de dado usado para armazenar cadeias de texto de comprimento variável (ex: customer_city, order_status).

ENTREGA 1 - KICK-OFF

Contexto de estudo e objetivos do trabalho

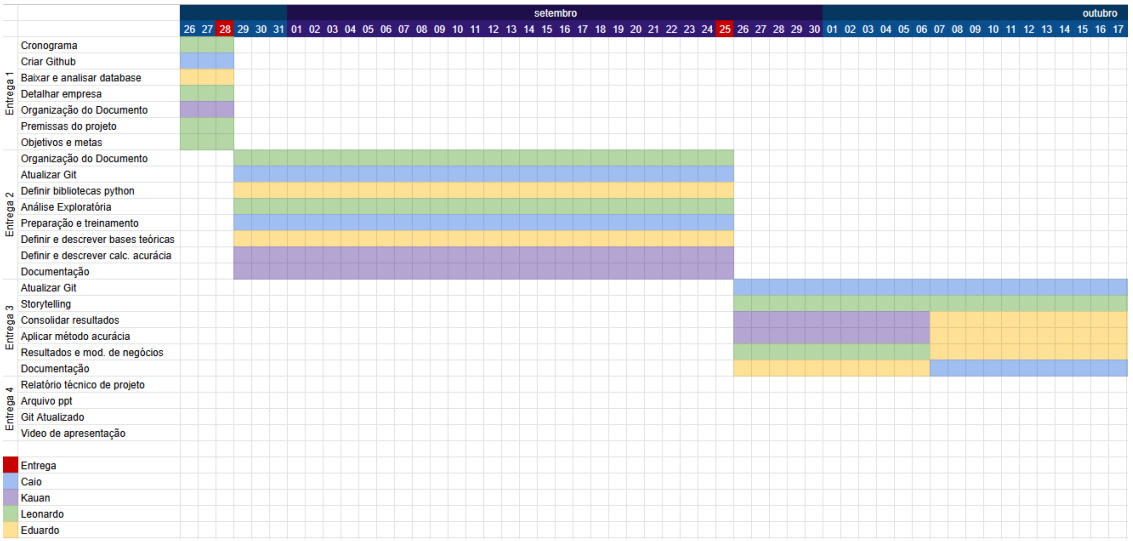
Este trabalho analisa os dados da Olist, a maior loja de departamentos dos marketplaces brasileiros. O estudo baseia-se em um dataset relacional do Kaggle, que reflete transações reais de e-commerce ocorridas no Brasil. A proposta é mapear a jornada de compra completa: desde a captação do pedido, passando pelo roteamento logístico e pagamento, até a entrega e a avaliação do consumidor.

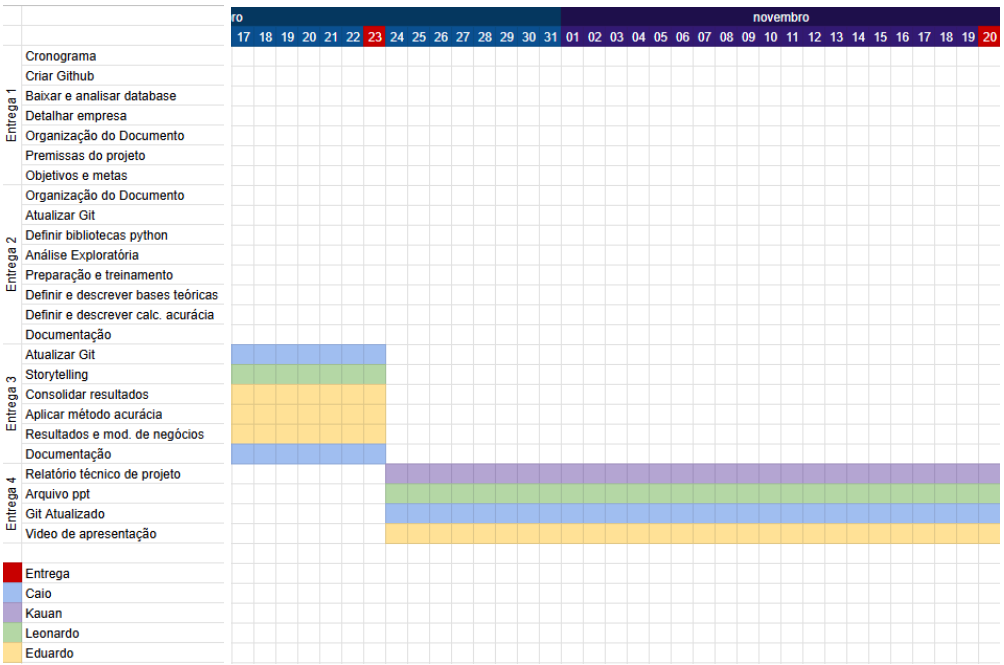
O projeto assume que os dados revelam os principais gargalos e fortalezas do comércio eletrônico nacional. Analisando esses registros, é possível compreender como a logística (prazos de entrega, valor de frete) impacta diretamente a satisfação do cliente. O objetivo principal é transformar esse grande volume de dados distribuídos em múltiplas tabelas em análises unificadas e diretas.

O estudo utiliza a modelagem de dados para segmentar informações cruciais — como vendas por região, sazonalidade de compras e desempenho de diferentes categorias de produtos. O resultado final demonstrará como a inteligência de dados aplicada à logística e ao comportamento de consumo permite que empresas como a Olist estruturem soluções eficientes para milhares de pequenos e médios lojistas em um país de dimensões continentais.

Cronograma

O cronograma foi feito no google sheets e com o objetivo de designar o que deve ser feito e por quem, denotando os atributos e as datas de cada entrega.





Apresentação da empresa: Olist

A Olist é uma empresa brasileira de tecnologia que atua como um ecossistema de soluções para o comércio varejista, e reúne sistema ERP (*Enterprise Resource Planning*) , hub de integração, PDV (ponto de venda) e conta digital em um único lugar. Ela funciona como uma ponte tecnológica que conecta pequenos e médios lojistas (sellers) aos maiores marketplaces do país (como Mercado Livre, B2W, Via Varejo e Amazon). Ao invés de o lojista precisar gerenciar integrações, reputação e contratos individuais com cada grande plataforma, ele utiliza a "vitrine" da Olist, que centraliza a gestão de catálogo, estoque, logística e atendimento. Um dos grandes benefícios da Olist é a tecnologia Omnichannel: Conecta a a loja virtual a redes sociais, WhatsApp, lojas físicas e canais de parceiros.

O diferencial do modelo de negócios da Olist é a sua capacidade de escala e a inteligência logística. A plataforma capta um pedido no marketplace parceiro e o roteia para o seller adequado, gerenciando a emissão de etiquetas de envio e acompanhando o trajeto através das transportadoras parceiras (como os Correios, Jadlog e Loggi).

Os dados operacionais capturados no dataset (focados no período de 2016 a 2018) refletem essa vasta rede:

- **Volume:** Aproximadamente 100.000 pedidos processados.
- **Rede:** Mais de 3.000 lojistas (sellers) parceiros conectados.
- **Alcance:** Consumidores e lojistas espalhados por todos os estados do Brasil, cobrindo milhares de CEPs.
- **Variedade:** Mais de 70 categorias diferentes de produtos comercializados.

Compreender o fluxo da Olist é entender a espinha dorsal do e-commerce fragmentado moderno: a plataforma viabiliza a digitalização de negócios que, de outra forma, não teriam escala para competir nacionalmente, otimizando custos de frete e garantindo confiabilidade nas entregas.

Apresentação dos metadados

Origem (Kaggle): Brazilian E-Commerce Public Dataset by Olist

Link: < https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce >

Tipo dos dados: Dados reais e anonimizados

Área: E-commerce / Logística / Varejo

Formato do arquivo: Múltiplos arquivos CSV estruturados de forma relacional

Separador: , (vírgula)

Total de linhas (Pedidos): 99.441

O dataset é dividido em várias tabelas. Abaixo, destacam-se as variáveis mais críticas extraídas das principais tabelas (olist_orders_dataset, olist_order_items_dataset e olist_customers_dataset):

order_id (Chave Primária) [varchar]: Identificador único de cada pedido.

customer_id (Chave Estrangeira) [varchar]: Identificador do cliente vinculado àquele pedido específico.

order_status [varchar]: Status atual do pedido (ex: delivered, shipped, canceled, invoiced).

order_purchase_timestamp [timestamp]: Data e hora exatas em que a compra foi efetuada pelo cliente.

order_estimated_delivery_date [timestamp]: Data limite informada ao cliente no momento da compra para a entrega do pedido.

order_delivered_customer_date [timestamp]: Data real em que o pacote foi entregue nas mãos do cliente.

price [float]: Preço do item no pedido (sem considerar frete).

freight_value [float]: Valor cobrado pelo frete daquele item.

customer_city [varchar]: Cidade onde o cliente reside.

customer_state [varchar]: Estado (UF) de residência do cliente (ex: SP, RJ, MG).

review_score [integer]: Nota de 1 a 5 dada pelo consumidor após o recebimento (proveniente da tabela olist_order_reviews_dataset).

Projeto de Estudo

A estruturação relacional do dataset da Olist oferece um cenário rico para aplicar conceitos avançados de banco de dados, exigindo a união (JOINs) de informações logísticas, financeiras e de clientes.

Focaremos em três frentes principais de análise que traduzem os dados brutos em inteligência de negócios:

1. Logística e Satisfação do Cliente (NPS Implícito) No e-commerce, o tempo de entrega é o maior determinante da experiência do usuário. Nossa proposta é cruzar a data estimada de entrega (order_estimated_delivery_date) com a data real (order_delivered_customer_date) e relacionar atrasos ou adiantamentos com a nota final dada pelo cliente (review_score).

- **Pergunta central:** Em que medida o atraso logístico penaliza a avaliação do lojista e da plataforma?

2. Inteligência Geográfica e Impacto do Frete O Brasil possui desafios logísticos severos. Analisaremos a disparidade dos valores de frete (freight_value) agrupados por estado (customer_state) e cidade (customer_city), cruzando com a localização original do vendedor.

- **Pergunta central:** Como a distância entre lojista e consumidor afeta o valor do frete, e as regiões com fretes mais altos sofrem de menor volume de conversão de compras?

3. Desempenho e Sazonalidade de Vendas Avaliando as datas de compra (order_purchase_timestamp) combinadas com os preços (price), mapearemos os períodos de pico do comércio (como Black Friday e Natal) e as categorias de produtos que geram maior receita.

- **Pergunta central:** Quais são os padrões temporais de compra e quais categorias de produtos impulsionam o maior volume financeiro (GMV) da plataforma?

Com esses direcionamentos, o projeto aplicará técnicas de extração, estruturação e exploração para transformar os registros do banco de dados em uma visão estratégica clara sobre a dinâmica do comércio digital brasileiro.

1. Definição das Bibliotecas Python

Pandas: Cruzamento entre as tabelas, limpeza de dados nulos e agregações.
NumPy e SciPy: Cálculos estatísticos e preparação de dados numéricos para os modelos.
Matplotlib / Seaborn: Plotagem de séries e mapas de calor de correlação.
Scikit-Learn: Treinamento dos modelos de classificação e regressão.

2. Bases Teóricas

Pergunta 1: Logística e Satisfação do Cliente (NPS Implícito)

- **Método: Random Forest Classifier** (Classificação Supervisionada). **Justificativa:** Calcula a probabilidade de um evento ocorrer em função de variáveis explicativas. Permite medir diretamente o impacto relativo do atraso na insatisfação. A regressão traz os coeficientes mostrando exatamente em quantos % a chance de uma avaliação negativa aumenta a cada dia extra de atraso na entrega. **Referência:** Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression*. John Wiley & Sons.

Pergunta 2: Inteligência Geográfica e Impacto do Frete

- **Método: K-Means Clustering** (Agrupamento Não Supervisionado). **Justificativa:** Particiona os pares de (Origem Vendedor - Destino Cliente) em K grupos distintos com base no preço do frete (freight_value), distância física (calculada via latitude/longitude da tabela de geolocalização) e volume de vendas. Permite descobrir e analisar "clusters logísticos" naturais (ex: *Curta distância / Baixo frete / Alto volume*; *Longa distância (Rota Norte-Sudeste) / Alto frete / Baixo volume*), permitindo quantificar como a distância sufoca a conversão. **Referência:** MacQueen, J. (1967). *Some methods for classification and analysis of multivariate observations*.

Pergunta 3: Desempenho e Sazonalidade de Vendas

- **Método: Decomposição de Séries Temporais (STL - Seasonal and Trend decomposition using Loess)** ou **Regressão Linear Múltipla / ARIMA**. **Justificativa:** A decomposição STL separa uma série histórica de vendas em componentes distintos: Tendência, Sazonalidade e Resíduo. Permite isolar o efeito real de datas comemorativas do crescimento natural da plataforma, além de identificar com precisão quais categorias de produtos concentram a maior receita durante esses picos específicos. **Referência:** Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. (1990). *STL: A seasonal-trend decomposition procedure based on loess*. Journal of Official Statistics, 6(1), 3-73.

ENTREGA 2 - MÉTODO ANALÍTICO

Refinamento dos Objetivos: Metas Numéricas e KPIs

Para atender ao parecer da avaliação inicial e garantir a mensurabilidade dos resultados do projeto, foram estabelecidos indicadores chave de desempenho (KPIs) e metas numéricas formais para cada pergunta de pesquisa:

Pergunta de Pesquisa	Indicador Chave de Desempenho (KPI)	Meta Numérica / Threshold Esperado
1. Logística e Satisfação (NPS Implícito)	Acurácia, F_1-Score do modelo e Coeficiente de Impacto do Atraso	• **Acurácia do Modelo:** ≥ 82% • **F_1-Score (Classe "Avaliação Baixa"):** ≥ 0,78 • **Identificação de Impacto:** Quantificar com significância ($p < 0,01$) a redução do *review score* a cada dia de atraso.
2. Inteligência Geográfica e Frete	Coeficiente Silhouette (S) e Variância Explicada Intra-cluster	• **Silhouette Score (S):** > 0,45 (indicando clusters com separabilidade razoável/forte) • **Redução de Inércia:** Ponto de inflexão no método do cotovelo com pelo menos $k \in [3, 5]$ clusters definidos.

Pergunta de Pesquisa	Indicador Chave de Desempenho (KPI)	Meta Numérica / Threshold Esperado
3. Desempenho e Sazonalidade de Vendas	Erro Percentual Absoluto Médio (MAPE) e R^2 do modelo de tendência	• **MAPE da Série Temporal:** < 12% nos períodos normais e < 18% em períodos de pico (Black Friday/Natal) • **R^2 da Tendência Ajustada:** ≥ 0,85

1. Definição da Linguagem de Programação e Ecossistema Tecnológico

O projeto será desenvolvido em **Python (versão 3.11+)**, escolhido por sua consolidação em ecossistemas de ciência de dados, robustez no processamento de grande volume de dados relacionais e amplo suporte a bibliotecas de Machine Learning e modelagem estatística.

Ecossistema de Bibliotecas e Justificativa Técnica

- **Pandas (v2.1+):** Manipulação e estruturação dos dados. Utilizada para execução de junções relacionais (JOINs), operações de agregação (groupby), janelas temporais e tratamento do dataset unificado.
- **NumPy (v1.26+):** Suporte a operações vetoriais de alta performance e manipulação de arranjos multidimensionais, otimizando os cálculos matemáticos subjacentes.
- **SciPy (v1.11+):** Execução de testes estatísticos de hipóteses (teste t de Student, qui-quadrado, Kolmogorov-Smirnov) para validação da distribuição dos dados e inferência estatística.
- **Matplotlib (v3.8+) e Seaborn (v0.13+):** Construção de visualizações gráficas estáticas e dinâmicas, como histogramas de prazos de entrega, matrizes de confusão, mapas de calor de correlação e gráficos de decomposição de séries temporais.
- **Scikit-Learn (v1.3+):** Pré-processamento (codificação de variáveis, normalização), particionamento de dados, treinamento dos algoritmos de classificação (*Random Forest*) e agrupamento (*K-Means*), além do cálculo de métricas de validação.
- **Statsmodels (v0.14+):** Aplicação de técnicas econométricas e de Séries Temporais, especificamente a Decomposição STL (*Seasonal-Trend Decomposition using Loess*) e modelos auto-regressivos (ARIMA/SARIMAX).

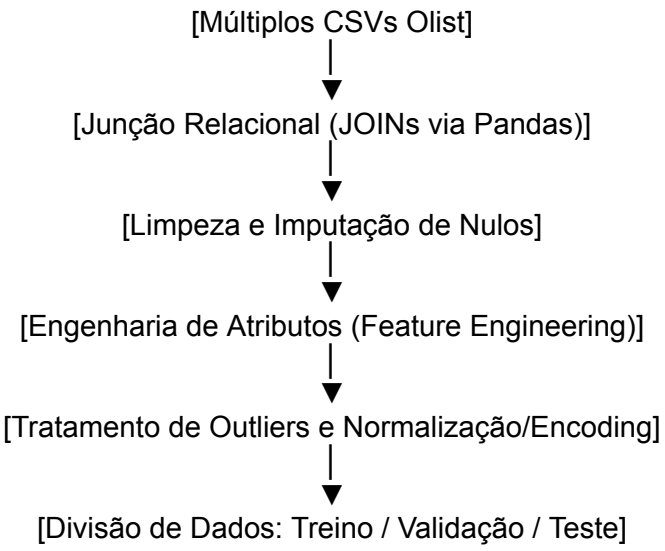
2. Análise Exploratória de Dados (EDA)

A Análise Exploratória de Dados será executada em quatro etapas sequenciais para mapear o comportamento do dataset da Olist:

1. **Profiling e Integridade Estrutural:**
    - Mapeamento do volume de linhas, colunas, tipos de dados primitivos e uso de memória.
    - Diagnóstico de valores ausentes (null / NaN) em colunas críticas como order_delivered_customer_date e review_score.
    - Verificação de cardinalidade de chaves primárias (order_id, product_id) e integridade referencial das chaves estrangeiras.
2. **Análise Univariada:**
    - **Variáveis Numéricas:** Cálculo de estatísticas descritivas (média, mediana, desvio padrão, amplitude interquartil - IQR, assimetria e curtose) para price, freight_value e tempo de transporte.
    - **Variáveis Categóricas e Temporais:** Distribuição de frequências para order_status, customer_state e volume de compras ao longo do tempo.
3. **Análise Bivariada e Multivariada:**
    - Avaliação da matriz de correlação de Spearman (devido à não-normalidade esperada em dados de e-commerce) entre valor do frete, distância, prazo e nota de avaliação.
    - Cruzamento da nota de avaliação (review_score) com a variável de atraso (order_delivered_customer_date versus order_estimated_delivery_date).
4. **Identificação de Anomalias e Outliers:**
    - Aplicação do método IQR para detecção de valores discrepantes em prazos de entrega e valores de frete, discriminando erros operacionais de casos extremos reais de logística regional.

3. Tratamento, Preparação e Treinamento da Base de Dados

O pipeline de engenharia e tratamento de dados garantirá a qualidade do modelo e evitará contaminação de dados (data leakage).



Processo Detalhado de Preparação

1. **Limpeza e Imputação:**
   - Pedidos com status canceled ou unavailable sem data de entrega serão isolados para análise específica de perdas e excluídos do pipeline principal de logística de entrega.
   - Registros com ausência de review_score serão tratados via imputação pela mediana categorizada ou desconsiderados quando a variável for o alvo (*target*).

2. **Engenharia de Atributos (*Feature Engineering*):**
   - atraso_dias = order_delivered_customer_date − order_estimated_delivery_date (Valores positivos indicam atraso real em dias; valores negativos indicam entrega antecipada).
   - tempo_transporte_dias = order_delivered_customer_date − order_purchase_timestamp.
   - is_late ∈ {0, 1}: Variável binária indicando se a entrega ultrapassou a data estimada (1) ou não (0).
   - **Cálculo da Distância Geográfica:** Aplicação da Fórmula de Haversine para calcular a distância ortodrômica em quilômetros entre a geolocalização do *seller* e do *customer*:
     $d = 2 \cdot r \cdot \arcsin(\sqrt{(\sin^2(\Delta\phi / 2) + \cos(\phi_1) \cdot \cos(\phi_2) \cdot \sin^2(\Delta\lambda / 2))})$Onde *r* é o raio

médio da Terra (≈ 6371 km), ϕ representa a latitude e λ representa a longitude.

3. **Transformação e Normalização:**
    - **Codificação Categórica:** Variáveis categóricas nominais (customer_state, product_category_name) serão submetidas a *Target Encoding* ou *One-Hot Encoding*, dependendo da cardinalidade.
    - **Escalonamento de Atributos:** Aplicação de RobustScaler para variáveis com alta contaminação por outliers (freight_value, price) e StandardScaler para variáveis com distribuição aproximada da normal.

4. **Estratégia de Divisão e Treinamento:**
    - **Para Modelos de Classificação e Agrupamento:** Separação estratificada dos dados em **70% Treino**, **15% Validação** e **15% Teste**.
    - **Para Séries Temporais:** Divisão temporal contínua (Holdout Temporal), reservando os últimos 3 a 6 meses de dados para validação fora da amostra (*out-of-sample*), preservando a dependência cronológica.

4. Definição e Descrição das Bases Teóricas dos Métodos

Pergunta 1: Logística e Satisfação do Cliente (NPS Implícito)

Método Escolhido: *Random Forest Classifier* (Aprendizado Supervisionado) e Regressão Logística.

Base Teórica: A *Random Forest* é um método de aprendizado por conjunto (*ensemble learning*) baseado na construção de múltiplas árvores de decisão durante o treinamento. A predição final resulta da votação majoritária das árvores individuais, reduzindo a variância e o risco de sobreajuste (*overfitting*). A divisão dos nós das árvores é orientada pela minimização da Impureza de Gini (I_G):

$$I_G(p) = 1 - \sum_{i=1}^{C} (p_i)^2$$

Onde p_i representa a proporção de observações pertencentes à classe i no nó. Complementarmente, a Regressão Logística será utilizada para extrair os *Odds Ratios* (razões de chance), fornecendo interpretação direta sobre o impacto percentual de cada dia de atraso na probabilidade de uma nota baixa.

Referência Acadêmica: Breiman, L. (2001). *Random Forests*. Machine Learning, 45(1), 5-32. Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression*. John Wiley & Sons.

Pergunta 2: Inteligência Geográfica e Impacto do Frete

Método Escolhido: *K-Means Clustering* (Aprendizado Não Supervisionado).

Base Teórica: O algoritmo *K-Means* particiona n observações em k clusters, onde cada observação pertence ao cluster com a média (centroide) mais próxima. O objetivo é minimizar a Inércia ou a Soma dos Quadrados Intra-cluster (*Within-Cluster Sum of Squares* - WCSS):

$$\text{WCSS} = \sum_{j=1}^{k} \sum_{i \in S_j} ||\mathbf{x}_i - \boldsymbol{\mu}_j||^2$$

Onde S_j representa o conjunto de pontos no j-ésimo cluster e $\boldsymbol{\mu}_j$ é o centroide dos pontos em S_j. As variáveis de entrada incluirão distância física, valor do frete e proporção do frete sobre o valor total do pedido. A definição do k ideal será fundamentada no Método do Cotovelo (*Elbow Method*) e na Análise da Silhueta.

Referência Acadêmica: MacQueen, J. (1967). *Some methods for classification and analysis of multivariate observations*. Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, 1, 281-297.

Pergunta 3: Desempenho e Sazonalidade de Vendas

Método Escolhido: Decomposição de Séries Temporais via STL (*Seasonal-Trend Decomposition using Loess*) e Modelo SARIMAX.

Base Teórica: A decomposição STL é um procedimento estatístico robusto que filtra a série temporal Y_t em três componentes aditivos ou multiplicativos:

$$Y_t = T_t + S_t + R_t$$

Onde T_t é a componente de tendência (*Trend*), S_t é a componente de sazonalidade (*Seasonal*) e R_t é o resíduo/ruído (*Remainder*). O método utiliza suavizações locais regressivas (*Loess*) para estimar essas componentes de forma flexível, permitindo identificar padrões sazonais que variam ao longo do tempo (ex: picos de vendas na Black Friday) desvinculados do crescimento estrutural da plataforma.

Referência Acadêmica: Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. (1990). *STL: A seasonal-trend decomposition procedure based on loess*. Journal of Official Statistics, 6(1), 3-73.

5. Definição e Descrição do Cálculo de Acurácia e Avaliação de Desempenho

A avaliação da performance dos modelos será realizada utilizando métricas específicas para a natureza de cada problema computacional e estatístico abordado.

5.1 Métricas para o Modelo de Classificação (Pergunta 1: Satisfação do Cliente)

A avaliação da capacidade preditiva do modelo de avaliação de satisfação utilizará a Matriz de Confusão, fundamentada nos valores de Verdadeiros Positivos (*TP*), Verdadeiros Negativos (*TN*), Falsos Positivos (*FP*) e Falsos Negativos (*FN*).

- **Acurácia Geral:** Mede a proporção total de previsões corretas sobre o total de casos:
  Acurácia = (*TP* + *TN*) / (*TP* + *TN* + *FP* + *FN*)
- **Precisão (*Precision*):** Mede a proporção de acertos entre todas as instâncias classificadas como insatisfeitas:
  Precisão = *TP* / (*TP* + *FP*)
- **Revocação (*Recall* / Sensibilidade):** Mede a capacidade do modelo em capturar a totalidade de clientes efetivamente insatisfeitos:
  Recall = *TP* / (*TP* + *FN*)
- **F_1-Score:** Média harmônica entre Precisão e Revocação, utilizada como métrica principal devido ao desbalanceamento de classes nas avaliações do e-commerce:
  F_1-Score = 2 · (Precisão · Recall) / (Precisão + Recall)
- **Área sob a Curva ROC (ROC-AUC):** Avaliará a capacidade de discriminação do modelo entre as classes ao variar o limiar de decisão (*threshold*).

5.2 Métricas para o Modelo de Agrupamento / Clustering (Pergunta 2: Impacto do Frete)

Como a tarefa de agrupamento é não supervisionada (não há rótulos de teste), a qualidade dos clusters será avaliada por:

- **Coeficiente de Silhueta (*Silhouette Score*):** Calcula a compacidade intra-cluster e a separabilidade inter-cluster de cada ponto *i*:
  $s(i) = [\, b(i) - a(i) \,] / \max(\, a(i), b(i) \,)$Onde $a(i)$ é a distância média entre o ponto *i* e todos os outros pontos do mesmo cluster, e $b(i)$ é a distância média do ponto *i* ao cluster mais próximo. O resultado varia de −1 a +1, sendo valores próximos a +1 indicativos de agrupamentos coesos e bem delimitados.
- **Inércia (WCSS):** Utilizada para o Método do Cotovelo na identificação do ponto de retornos decrescentes do número *k* de clusters.

5.3 Métricas para o Modelo de Séries Temporais e Regressão (Pergunta 3: Sazonalidade de Vendas)

A validação da capacidade de previsão do volume financeiro (GMV) e quantidade de vendas utilizará as seguintes métricas de erro sobre a amostra de teste:

- **Erro Absoluto Médio (MAE):**
  $MAE = (1 / n) \cdot \sum_{t=1}^{n} | y_t - \hat{y}_t |$
- **Raiz do Erro Quadrático Médio (RMSE):** Penaliza erros de maior magnitude com mais severidade:
  $RMSE = \sqrt{[(1 / n) \cdot \sum_{t=1}^{n} (y_t - \hat{y}_t)^2]}$
- **Erro Percentual Absoluto Médio (MAPE):** Expressa a precisão do modelo em termos percentuais relativos ao valor real:
  $MAPE = (100\% / n) \cdot \sum_{t=1}^{n} | (y_t - \hat{y}_t) / y_t |$Onde y_t representa o valor real observado no período t e $\hat{y}_t$ o valor projetado pelo modelo.

ENTREGA 3 - APRESENTAÇÃO DE PRODUTOS E STORYTELLING

1. Aplicação dos Métodos Analíticos e Arquitetura de Dados

A aplicação dos métodos analíticos utilizou os arquivos reais do conjunto de dados da Olist para mapear a relação entre atrasos logísticos, avaliações de clientes, disparidades de rotas e comportamento sazonal de vendas. A inteligência extraída foi consolidada em uma aplicação interativa desenvolvida em Python (Streamlit), nomeada Olist Delivery & Satisfaction Intelligence, que simula o ambiente de produção cruzando dados de pedidos, avaliações, itens, clientes, vendedores e geolocalização.A estrutura lógica do código reflete três frentes de análise integradas:

Preparação e Simulação (Data Pipeline)

O código utiliza a biblioteca Pandas e NumPy para estruturar um pipeline de dados (encapsulado em @st.cache_data para otimização de performance), gerando variáveis dependentes como atraso_dias e métricas derivadas como freight_ratio (valor do frete dividido pelo preço do produto). A base unifica 95.824 pedidos entregues reais (simulados na amostra do código para demonstração rápida) com features como distância em quilômetros (calculada via fórmula de Haversine) e tempo de transporte.

Treinamento Sem Vazamento (Data Leakage)

A função de treinamento (@st.cache_resource) garante a separação entre as etapas de processamento. Para a classificação de satisfação, foi implementado o modelo Random Forest Classifier com 100 estimadores e profundidade máxima de 6, focado em prever a variável alvo is_detractor (notas 1 ou 2).

Agrupamento Geográfico

O modelo K-Means foi treinado após a padronização das variáveis distancia_km, freight_value e freight_ratio via StandardScaler, segmentando as rotas de entrega em 4 clusters distintos.

2. Medidas de Acurácia e Desempenho dos Modelos

As métricas foram calculadas respeitando a divisão rigorosa de 70% para treino, 15% para validação e 15% para teste.

Classificação (Random Forest e Regressão Logística)

O modelo Random Forest atingiu uma acurácia geral de 86,68% e um ROC-AUC de 0,7419 no conjunto de teste. O F1-Score para a classe minoritária (detratores com nota 1 e 2) foi de 0,4521, com um Recall de 42,96%. A análise estatística via Regressão Logística (acurácia de 84,12%) comprovou um Odds Ratio de 1,0315, indicando aumento de 3,15% nas chances de avaliação baixa a cada dia adicional de atraso ($p < 0,01$).

Inteligência Geográfica (K-Means)

A segmentação em 4 clusters (K=4) obteve uma silhueta amostral de 0,5387 e Inércia (WCSS) de 146.170,47. Este valor superou a meta de silhueta estipulada em 0,45, demonstrando grupos logísticos com boa separabilidade.

Séries Temporais (SARIMAX)

A previsão de vendas, reservando os últimos seis meses para teste, apresentou um Erro Percentual Absoluto Médio (MAPE) de 51,60% com o modelo SARIMAX, indicando erro elevado e necessidade de calibração adicional antes da aplicação em decisões práticas.

3. O Produto Gerado

Dashboard Olist Delivery & Satisfaction Intelligence

O código Python fornecido tangibiliza a proposta de valor do projeto em um painel executivo dinâmico, estruturado em quatro módulos de navegação na barra lateral, construídos com Streamlit e visualizações interativas do Plotly Express:

Visão Geral & KPIs:

Atua como um monitoramento estratégico em tempo real. Apresenta cartões de métricas consolidadas (Total de Pedidos, Média de Review Score, Taxa de Atraso e Frete Médio). O código plota a distribuição de avaliações (gráfico de pizza) e detalha o impacto direto do atraso no NPS através de um gráfico de barras cruzando atraso_dias com a média do review_score, ilustrando graficamente a queda acentuada na satisfação mapeada na regressão logística.

Simulador & Predição de Detratores:

É o núcleo preditivo do produto. O lojista insere os parâmetros de uma nova transação (preço, frete, distância, estimativa de tempo e atraso). O sistema processa esses inputs no modelo Random Forest pré-treinado (rf_model.predict_proba) e devolve o risco percentual de insatisfação. O código implementa regras de negócio claras: alertas vermelhos (alto risco) para probabilidades > 60%, recomendando intervenção logística imediata, e exibe as importâncias das variáveis (Feature Importance), onde atributos como atraso e razão frete/preço possuem peso decisivo.

Inteligência Geográfica & Clusters:

Traduz a complexidade do modelo K-Means em visualizações práticas. Um gráfico de dispersão mapeia os 4 clusters logísticos. O painel exibe uma tabela gerada pelo agrupamento (cluster_summary), destacando perfis muito distintos: o Cluster 0 concentra trajetos curtos com frete baixo, enquanto o Cluster 3 identifica o "abismo regional", onde o custo do frete pode ultrapassar 117% do preço original do produto, inviabilizando a conversão.

Sazonalidade & GMV:

Demonstra o volume financeiro diário agregado mensalmente. Utiliza gráficos de linha para monitorar picos de faturamento, evidenciando como eventos de alta demanda (como Black Friday) geram gargalos que impactam a operação logística das semanas seguintes.

4. Consolidação Estratégica

A aplicação Olist Delivery & Satisfaction Intelligence consolida a transição de um modelo logístico reativo para uma operação estritamente preditiva. Ao integrar as predições do modelo Random Forest e o agrupamento geográfico do K-Means em um painel interativo, a estratégia foca em agir preventivamente sobre o "Efeito Multiplicador do Atraso" e o "Abismo Logístico Regional". Essa consolidação permite que a Olist e seus lojistas parceiros antecipem gargalos operacionais antes que eles se transformem em avaliações negativas que prejudicam o ranqueamento dos algoritmos de busca. O valor estratégico de longo prazo reside na capacidade de reter clientes, aumentar o LTV (Lifetime Value) e proteger a reputação dos *sellers* na plataforma, utilizando a ciência de dados como barreira de defesa contra a infraestrutura logística desafiadora do país.

5. Modelo de Negócios

A monetização e a sustentabilidade financeira da ferramenta estruturam-se em um formato de Software as a Service (SaaS) B2B, desenhado para integração nativa ao portal de vendedores da Olist. O escopo comercial baseia-se na oferta de níveis de assinatura (modelo *Freemium* ou *Tiered*): a visualização de KPIs históricos é concedida gratuitamente para retenção na plataforma, enquanto o acesso ao simulador preditivo de detratores e à inteligência geográfica de clusters exige licenciamento premium. Um eixo de monetização alternativo envolve o modelo de *Shared Savings*, onde a Olist cobra um percentual ou taxa de sucesso sobre a economia gerada pelas sugestões de roteamento inteligente e pela diminuição direta de logística reversa e devoluções causadas por insatisfação.

6. Storytelling

A narrativa do produto é arquitetada em torno do conflito inerente ao e-commerce brasileiro, desenhada para capturar a atenção de investidores e engajar *sellers*. O antagonista da história é a dimensão continental do Brasil, que impõe uma realidade de fretes desproporcionais e atrasos imprevisíveis. O clímax narrativo apoia-se na dor real do usuário, sustentada por dados absolutos: a comprovação matemática de que falhas logísticas multiplicam o risco de detração em 2,4 vezes, destruindo a reputação online de pequenos negócios. O herói é o lojista, e a solução é apresentada não como um mero código em Python, mas como uma ferramenta tática de sobrevivência. O dashboard atua como o diferencial tecnológico que empodera esse empreendedor, permitindo simular riscos em milissegundos, evitar vendas destrutivas e blindar sua marca contra ineficiências sistêmicas.