

MACKENZIE - BANCO DE DADOS - 2026.2

PROJETO APLICADO II

COMPONENTE CURRICULAR:		Banco de Dados - Projeto Aplicado II
GRUPO Query NOME COMPLETO DOS ALUNOS:	Caio Balista Ferreira Pedretti	RA: 10751989
	Kauan Lima da Silva	RA: 10748047
	Leonardo de Barros Magalhães	RA: 10752304
	Eduardo Pereira Callado Neto	RA: 10750949

A2 - Aplicando Conhecimento - 25/09/2026

Nome da empresa:

Olist Plataforma de Ecommerce

Link para Github:

<https://github.com/CaioPedretti/Projeto-Aplicado-II-Grupo-Query>

Sumário

Sumário.....	1
Glossário.....	2
ENTREGA 1 - KICK-OFF.....	3
Contexto de estudo e objetivos do trabalho.....	3
Cronograma.....	4
Apresentação da empresa: Olist.....	5
Apresentação dos metadados.....	6
Projeto de Estudo.....	7
ENTREGA 2 - MÉTODO ANALÍTICO.....	9
Refinamento dos Objetivos: Metas Numéricas e KPIs.....	9
1. Definição da Linguagem de Programação e Ecossistema Tecnológico.....	10
Ecossistema de Bibliotecas e Justificativa Técnica.....	10
2. Análise Exploratória de Dados (EDA).....	11
3. Tratamento, Preparação e Treinamento da Base de Dados.....	12
Processo Detalhado de Preparação.....	12
4. Definição e Descrição das Bases Teóricas dos Métodos.....	14
Pergunta 1: Logística e Satisfação do Cliente (NPS Implícito).....	14
Pergunta 2: Inteligência Geográfica e Impacto do Frete.....	14
Pergunta 3: Desempenho e Sazonalidade de Vendas.....	15
5. Definição e Descrição do Cálculo de Acurácia e Avaliação de Desempenho.....	16
5.1 Métricas para o Modelo de Classificação (Pergunta 1: Satisfação do Cliente)....	16
5.2 Métricas para o Modelo de Agrupamento / Clustering (Pergunta 2: Impacto do Frete).....	16
5.3 Métricas para o Modelo de Séries Temporais e Regressão (Pergunta 3: Sazonalidade de Vendas).....	17



Glossário

Chave Primária (Primary Key): Identificador único e exclusivo para cada registro dentro de uma tabela. No contexto do trabalho, representada por colunas como `order_id` e `customer_id`, garantindo a rastreabilidade exata de cada pedido e cliente.

Chave Estrangeira (Foreign Key): Coluna ou grupo de colunas em uma tabela que provê um link para os dados em outra tabela, fundamental para a estrutura relacional do dataset da Olist.

CSV (Comma-Separated Values): Formato de arquivo simples que armazena dados tabulares em texto puro. Formato dos arquivos do dataset.

Dataset: Conjunto de dados estruturados. Refere-se aos arquivos extraídos do Kaggle contendo cerca de 100.000 pedidos reais anonimizados.

E-commerce / Marketplace: Modelo de comércio eletrônico onde a plataforma (neste caso, conectada pela Olist) atua como um shopping virtual, permitindo que vários lojistas vendam seus produtos em um único espaço.

Float: Tipo de dado numérico para valores com casas decimais (ex: `price`, `freight_value`).

Kaggle: Plataforma online focada em ciência de dados e machine learning, que hospeda competições e disponibiliza grandes conjuntos de dados (datasets) públicos para estudo e análise.

Metadados: "Dados sobre os dados". São as informações que descrevem a estrutura e o conteúdo do dataset, como o tipo de dado de cada coluna, o que ela significa, seus valores máximos/mínimos e sua codificação.

Timestamp: Tipo de dado utilizado para registrar a data e hora exatas de um evento (ex: `order_purchase_timestamp`).

UTF-8: Padrão de codificação de caracteres utilizado mundialmente que garante que textos, acentos e símbolos de diversos idiomas sejam interpretados e exibidos corretamente pelo computador.

Varchar: Tipo de dado usado para armazenar cadeias de texto de comprimento variável (ex: `customer_city`, `order_status`).



ENTREGA 1 - KICK-OFF

Contexto de estudo e objetivos do trabalho



Este trabalho analisa os dados da Olist, a maior loja de departamentos dos marketplaces brasileiros. O estudo baseia-se em um dataset relacional do Kaggle, que reflete transações reais de e-commerce ocorridas no Brasil. A proposta é mapear a jornada de compra completa: desde a captação do pedido, passando pelo roteamento logístico e pagamento, até a entrega e a avaliação do consumidor.

O projeto assume que os dados revelam os principais gargalos e fortalezas do comércio eletrônico nacional. Analisando esses registros, é possível compreender como a logística (prazos de entrega, valor de frete) impacta diretamente a satisfação do cliente. O objetivo principal é transformar esse grande volume de dados distribuídos em múltiplas tabelas em análises unificadas e diretas.

O estudo utiliza a modelagem de dados para segmentar informações cruciais — como vendas por região, sazonalidade de compras e desempenho de diferentes categorias de produtos. O resultado final demonstrará como a inteligência de dados aplicada à logística e ao comportamento de consumo permite que empresas como a Olist estruturem soluções eficientes para milhares de pequenos e médios lojistas em um país de dimensões continentais.

Cronograma

O cronograma foi feito no google sheets e com o objetivo de designar o que deve ser feito e por quem, denotando os atributos e as datas de cada entrega.





Apresentação da empresa: Olist

A Olist é uma empresa brasileira de tecnologia que atua como um ecossistema de soluções para o comércio varejista, e reúne sistema ERP (*Enterprise Resource Planning*), hub de integração, PDV (ponto de venda) e conta digital em um único lugar. Ela funciona como uma ponte tecnológica que conecta pequenos e médios lojistas (sellers) aos maiores marketplaces do país (como Mercado Livre, B2W, Via Varejo e Amazon). Ao invés de o lojista precisar gerenciar integrações, reputação e contratos individuais com cada grande plataforma, ele utiliza a "vitrine" da Olist, que centraliza a gestão de catálogo, estoque, logística e atendimento. Um dos grandes benefícios da Olist é a tecnologia Omnichannel: Conecta a loja virtual a redes sociais, WhatsApp, lojas físicas e canais de parceiros.

O diferencial do modelo de negócios da Olist é a sua capacidade de escala e a inteligência logística. A plataforma capta um pedido no marketplace parceiro e o roteia para o seller adequado, gerenciando a emissão de etiquetas de envio e acompanhando o trajeto através das transportadoras parceiras (como os Correios, Jadlog e Loggi).

Os dados operacionais capturados no dataset (focados no período de 2016 a 2018) refletem essa vasta rede:

- **Volume:** Aproximadamente 100.000 pedidos processados.
- **Rede:** Mais de 3.000 lojistas (sellers) parceiros conectados.
- **Alcance:** Consumidores e lojistas espalhados por todos os estados do Brasil, cobrindo milhares de CEPs.
- **Variedade:** Mais de 70 categorias diferentes de produtos comercializados.

Compreender o fluxo da Olist é entender a espinha dorsal do e-commerce fragmentado moderno: a plataforma viabiliza a digitalização de negócios que, de outra forma, não teriam escala para competir nacionalmente, otimizando custos de frete e garantindo confiabilidade nas entregas.



Apresentação dos metadados

Origem (Kaggle): Brazilian E-Commerce Public Dataset by Olist

Link: < <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce> >

Tipo dos dados: Dados reais e anonimizados

Área: E-commerce / Logística / Varejo

Formato do arquivo: Múltiplos arquivos CSV estruturados de forma relacional

Separador: , (vírgula)

Total de linhas (Pedidos): 99.441

O dataset é dividido em várias tabelas. Abaixo, destacam-se as variáveis mais críticas extraídas das principais tabelas (olist_orders_dataset, olist_order_items_dataset e olist_customers_dataset):

order_id (Chave Primária) [varchar]: Identificador único de cada pedido.

customer_id (Chave Estrangeira) [varchar]: Identificador do cliente vinculado àquele pedido específico.

order_status [varchar]: Status atual do pedido (ex: delivered, shipped, canceled, invoiced).

order_purchase_timestamp [timestamp]: Data e hora exatas em que a compra foi efetuada pelo cliente.

order_estimated_delivery_date [timestamp]: Data limite informada ao cliente no momento da compra para a entrega do pedido.

order_delivered_customer_date [timestamp]: Data real em que o pacote foi entregue nas mãos do cliente.

price [float]: Preço do item no pedido (sem considerar frete).

freight_value [float]: Valor cobrado pelo frete daquele item.

customer_city [varchar]: Cidade onde o cliente reside.

customer_state [varchar]: Estado (UF) de residência do cliente (ex: SP, RJ, MG).

review_score [integer]: Nota de 1 a 5 dada pelo consumidor após o recebimento (proveniente da tabela olist_order_reviews_dataset).

Projeto de Estudo

A estruturação relacional do dataset da Olist oferece um cenário rico para aplicar conceitos avançados de banco de dados, exigindo a união (JOINS) de informações logísticas, financeiras e de clientes.

Focaremos em três frentes principais de análise que traduzem os dados brutos em inteligência de negócios:

1. Logística e Satisfação do Cliente (NPS Implícito) No e-commerce, o tempo de entrega é o maior determinante da experiência do usuário. Nossa proposta é cruzar a data estimada de entrega (`order_estimated_delivery_date`) com a data real (`order_delivered_customer_date`) e relacionar atrasos ou adiantamentos com a nota final dada pelo cliente (`review_score`).

- **Pergunta central:** Em que medida o atraso logístico penaliza a avaliação do lojista e da plataforma?

2. Inteligência Geográfica e Impacto do Frete O Brasil possui desafios logísticos severos. Analisaremos a disparidade dos valores de frete (`freight_value`) agrupados por estado (`customer_state`) e cidade (`customer_city`), cruzando com a localização original do vendedor.

- **Pergunta central:** Como a distância entre lojista e consumidor afeta o valor do frete, e as regiões com fretes mais altos sofrem de menor volume de conversão de compras?

3. Desempenho e Sazonalidade de Vendas Avaliando as datas de compra (`order_purchase_timestamp`) combinadas com os preços (`price`), mapearemos os períodos de pico do comércio (como Black Friday e Natal) e as categorias de produtos que geram maior receita.

- **Pergunta central:** Quais são os padrões temporais de compra e quais categorias de produtos impulsionam o maior volume financeiro (GMV) da plataforma?

Com esses direcionamentos, o projeto aplicará técnicas de extração, estruturação e exploração para transformar os registros do banco de dados em uma visão estratégica clara sobre a dinâmica do comércio digital brasileiro.

1. Definição das Bibliotecas Python

Pandas: Cruzamento entre as tabelas, limpeza de dados nulos e agregações.

NumPy e SciPy: Cálculos estatísticos e preparação de dados numéricos para os modelos.

Matplotlib / Seaborn: Plotagem de séries e mapas de calor de correlação.

Scikit-Learn: Treinamento dos modelos de classificação e regressão.

2. Bases Teóricas

Pergunta 1: Logística e Satisfação do Cliente (NPS Implícito)

- **Método: Random Forest Classifier** (Classificação Supervisionada). **Justificativa:** Calcula a probabilidade de um evento ocorrer em função de variáveis explicativas. Permite medir diretamente o impacto relativo do atraso na insatisfação. A regressão traz os coeficientes mostrando exatamente em quantos % a chance de uma avaliação negativa aumenta a cada dia extra de atraso na entrega. **Referência:** Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression*. John Wiley & Sons.

Pergunta 2: Inteligência Geográfica e Impacto do Frete

- **Método: K-Means Clustering** (Agrupamento Não Supervisionado). **Justificativa:** Particiona os pares de (Origem Vendedor - Destino Cliente) em K grupos distintos com base no preço do frete (freight_value), distância física (calculada via latitude/longitude da tabela de geolocalização) e volume de vendas. Permite descobrir e analisar "clusters logísticos" naturais (ex: *Curta distância / Baixo frete / Alto volume*; *Longa distância (Rota Norte-Sudeste) / Alto frete / Baixo volume*), permitindo quantificar como a distância sufoca a conversão. **Referência:** MacQueen, J. (1967). *Some methods for classification and analysis of multivariate observations*.

Pergunta 3: Desempenho e Sazonalidade de Vendas

- **Método: Decomposição de Séries Temporais (STL - Seasonal and Trend decomposition using Loess) ou Regressão Linear Múltipla / ARIMA.** **Justificativa:** A decomposição STL separa uma série histórica de vendas em componentes distintos: Tendência, Sazonalidade e Resíduo. Permite isolar o efeito real de datas comemorativas do crescimento natural da plataforma, além de identificar com precisão quais categorias de produtos concentram a maior receita durante esses picos específicos. **Referência:** Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. (1990). *STL: A seasonal-trend decomposition procedure based on loess*. *Journal of Official Statistics*, 6(1), 3-73.

ENTREGA 2 - MÉTODO ANALÍTICO

Refinamento dos Objetivos: Metas Numéricas e KPIs

Para atender ao parecer da avaliação inicial e garantir a mensurabilidade dos resultados do projeto, foram estabelecidos indicadores chave de desempenho (KPIs) e metas numéricas formais para cada pergunta de pesquisa:

Pergunta de Pesquisa	Indicador Chave de Desempenho (KPI)	Meta Numérica / Threshold Esperado
1. Logística e Satisfação (NPS Implícito)	Acurácia, F_1 -Score do modelo e Coeficiente de Impacto do Atraso	• Acurácia do Modelo: $\geq 82\%$ • F_1-Score (Classe "Avaliação Baixa"): $\geq 0,78$ • Identificação de Impacto: Quantificar com significância ($p < 0,01$) a redução do <i>review score</i> a cada dia de atraso.
2. Inteligência Geográfica e Frete	Coeficiente Silhouette (S) e Variância Explicada Intra-cluster	• Silhouette Score (S): $> 0,45$ (indicando clusters com separabilidade razoável/forte) • Redução de Inércia: Ponto de inflexão no método do cotovelo com pelo menos $k \in [3, 5]$ clusters definidos.
3. Desempenho e Sazonalidade de Vendas	Erro Percentual Absoluto Médio (MAPE) e R^2 do modelo de tendência	• MAPE da Série Temporal: $< 12\%$ nos períodos normais e $< 18\%$ em períodos de pico (Black Friday/Natal) • R^2 da Tendência Ajustada: $\geq 0,85$

1. Definição da Linguagem de Programação e Ecossistema Tecnológico

O projeto será desenvolvido em **Python (versão 3.11+)**, escolhido por sua consolidação em ecossistemas de ciência de dados, robustez no processamento de grande volume de dados relacionais e amplo suporte a bibliotecas de Machine Learning e modelagem estatística.

Ecossistema de Bibliotecas e Justificativa Técnica

- **Pandas (v2.1+)**: Manipulação e estruturação dos dados. Utilizada para execução de junções relacionais (JOINS), operações de agregação (groupby), janelas temporais e tratamento do dataset unificado.
- **NumPy (v1.26+)**: Suporte a operações vetoriais de alta performance e manipulação de arranjos multidimensionais, otimizando os cálculos matemáticos subjacentes.
- **SciPy (v1.11+)**: Execução de testes estatísticos de hipóteses (teste t de Student, qui-quadrado, Kolmogorov-Smirnov) para validação da distribuição dos dados e inferência estatística.
- **Matplotlib (v3.8+) e Seaborn (v0.13+)**: Construção de visualizações gráficas estáticas e dinâmicas, como histogramas de prazos de entrega, matrizes de confusão, mapas de calor de correlação e gráficos de decomposição de séries temporais.
- **Scikit-Learn (v1.3+)**: Pré-processamento (codificação de variáveis, normalização), particionamento de dados, treinamento dos algoritmos de classificação (*Random Forest*) e agrupamento (*K-Means*), além do cálculo de métricas de validação.
- **Statsmodels (v0.14+)**: Aplicação de técnicas econométricas e de Séries Temporais, especificamente a Decomposição STL (*Seasonal-Trend Decomposition using Loess*) e modelos auto-regressivos (ARIMA/SARIMAX).

2. Análise Exploratória de Dados (EDA)

A Análise Exploratória de Dados será executada em quatro etapas sequenciais para mapear o comportamento do dataset da Olist:

1. Profiling e Integridade Estrutural:

- Mapeamento do volume de linhas, colunas, tipos de dados primitivos e uso de memória.
- Diagnóstico de valores ausentes (null / NaN) em colunas críticas como `order_delivered_customer_date` e `review_score`.
- Verificação de cardinalidade de chaves primárias (`order_id`, `product_id`) e integridade referencial das chaves estrangeiras.

2. Análise Univariada:

- **Variáveis Numéricas:** Cálculo de estatísticas descritivas (média, mediana, desvio padrão, amplitude interquartil - IQR, assimetria e curtose) para `price`, `freight_value` e tempo de transporte.
- **Variáveis Categóricas e Temporais:** Distribuição de frequências para `order_status`, `customer_state` e volume de compras ao longo do tempo.

3. Análise Bivariada e Multivariada:


- Avaliação da matriz de correlação de Spearman (devido à não-normalidade esperada em dados de e-commerce) entre valor do frete, distância, prazo e nota de avaliação.
- Cruzamento da nota de avaliação (`review_score`) com a variável de atraso (`order_delivered_customer_date` versus `order_estimated_delivery_date`).

4. Identificação de Anomalias e Outliers:

- Aplicação do método IQR para detecção de valores discrepantes em prazos de entrega e valores de frete, discriminando erros operacionais de casos extremos reais de logística regional.

3. Tratamento, Preparação e Treinamento da Base de Dados

O pipeline de engenharia e tratamento de dados garantirá a qualidade do modelo e evitará contaminação de dados (data leakage).



Processo Detalhado de Preparação

1. Limpeza e Imputação:

- Pedidos com status canceled ou unavailable sem data de entrega serão isolados para análise específica de perdas e excluídos do pipeline principal de logística de entrega.
- Registros com ausência de review_score serão tratados via imputação pela mediana categorizada ou desconsiderados quando a variável for o alvo (*target*).

2. Engenharia de Atributos (*Feature Engineering*):

- $\text{atraso_dias} = \text{order_delivered_customer_date} - \text{order_estimated_delivery_date}$ (Valores positivos indicam atraso real em dias; valores negativos indicam entrega antecipada).
- $\text{tempo_transporte_dias} = \text{order_delivered_customer_date} - \text{order_purchase_timestamp}$.
- $\text{is_late} \in \{0, 1\}$: Variável binária indicando se a entrega ultrapassou a data estimada (1) ou não (0).
- **Cálculo da Distância Geográfica:** Aplicação da Fórmula de Haversine para calcular a distância ortodrômica em quilômetros entre a geolocalização do *seller* e do *customer*.

$$d = 2 \cdot r \cdot \arcsin(\sqrt{(\sin^2(\Delta\phi / 2) + \cos(\phi_1) \cdot \cos(\phi_2) \cdot \sin^2(\Delta\lambda / 2))})$$
 Onde r é o raio médio da Terra (≈ 6371 km), ϕ representa a latitude e λ representa a longitude.

3. Transformação e Normalização:

- **Codificação Categórica:** Variáveis categóricas nominais (customer_state, product_category_name) serão submetidas a *Target Encoding* ou *One-Hot Encoding*, dependendo da cardinalidade.
- **Escalonamento de Atributos:** Aplicação de RobustScaler para variáveis com alta contaminação por outliers (freight_value, price) e StandardScaler para variáveis com distribuição aproximada da normal.

4. Estratégia de Divisão e Treinamento:

- **Para Modelos de Classificação e Agrupamento:** Separação estratificada dos dados em **70% Treino**, **15% Validação** e **15% Teste**.
- **Para Séries Temporais:** Divisão temporal contínua (Holdout Temporal), reservando os últimos 3 a 6 meses de dados para validação fora da amostra (*out-of-sample*), preservando a dependência cronológica.

4. Definição e Descrição das Bases Teóricas dos Métodos

Pergunta 1: Logística e Satisfação do Cliente (NPS Implícito)

Método Escolhido: *Random Forest Classifier* (Aprendizado Supervisionado) e Regressão Logística.

Base Teórica: A *Random Forest* é um método de aprendizado por conjunto (*ensemble learning*) baseado na construção de múltiplas árvores de decisão durante o treinamento. A predição final resulta da votação majoritária das árvores individuais, reduzindo a variância e o risco de sobreajuste (*overfitting*). A divisão dos nós das árvores é orientada pela minimização da Impureza de Gini (I_G):

$$I_G(p) = 1 - \sum_{i=1}^C (p_i)^2$$

Onde p_i representa a proporção de observações pertencentes à classe i no nó.

Complementarmente, a Regressão Logística será utilizada para extrair os *Odds Ratios* (razões de chance), fornecendo interpretação direta sobre o impacto percentual de cada dia de atraso na probabilidade de uma nota baixa.

Referência Acadêmica: Breiman, L. (2001). *Random Forests*. Machine Learning, 45(1), 5-32. Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression*. John Wiley & Sons.

Pergunta 2: Inteligência Geográfica e Impacto do Frete

Método Escolhido: *K-Means Clustering* (Aprendizado Não Supervisionado).

Base Teórica: O algoritmo *K-Means* particiona n observações em k clusters, onde cada observação pertence ao cluster com a média (centroide) mais próxima. O objetivo é minimizar a Inércia ou a Soma dos Quadrados Intra-cluster (*Within-Cluster Sum of Squares* - WCSS):

$$WCSS = \sum_{j=1}^k \sum_{i \in S_j} ||\mathbf{x}_i - \boldsymbol{\mu}_j||^2$$

Onde S_j representa o conjunto de pontos no j -ésimo cluster e $\boldsymbol{\mu}_j$ é o centroide dos pontos em S_j . As variáveis de entrada incluirão distância física, valor do frete e proporção do frete sobre o valor total do pedido. A definição do k ideal será fundamentada no Método do Cotovelo (*Elbow Method*) e na Análise da Silhueta.

Referência Acadêmica: MacQueen, J. (1967). *Some methods for classification and analysis of multivariate observations*. Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, 1, 281-297.

Pergunta 3: Desempenho e Sazonalidade de Vendas

Método Escolhido: Decomposição de Séries Temporais via STL (*Seasonal-Trend Decomposition using Loess*) e Modelo SARIMAX.

Base Teórica: A decomposição STL é um procedimento estatístico robusto que filtra a série temporal Y_t em três componentes aditivos ou multiplicativos:

$$Y_t = T_t + S_t + R_t$$

Onde T_t é a componente de tendência (*Trend*), S_t é a componente de sazonalidade (*Seasonal*) e R_t é o resíduo/ruído (*Remainder*). O método utiliza suavizações locais regressivas (*Loess*) para estimar essas componentes de forma flexível, permitindo identificar padrões sazonais que variam ao longo do tempo (ex: picos de vendas na Black Friday) desvinculados do crescimento estrutural da plataforma.

Referência Acadêmica: Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. (1990). *STL: A seasonal-trend decomposition procedure based on loess*. *Journal of Official Statistics*, 6(1), 3-73.

5. Definição e Descrição do Cálculo de Acurácia e Avaliação de Desempenho

A avaliação da performance dos modelos será realizada utilizando métricas específicas para a natureza de cada problema computacional e estatístico abordado.

5.1 Métricas para o Modelo de Classificação (Pergunta 1: Satisfação do Cliente)

A avaliação da capacidade preditiva do modelo de avaliação de satisfação utilizará a Matriz de Confusão, fundamentada nos valores de Verdadeiros Positivos (TP), Verdadeiros Negativos (TN), Falsos Positivos (FP) e Falsos Negativos (FN).

- **Acurácia Geral:** Mede a proporção total de previsões corretas sobre o total de casos:
$$\text{Acurácia} = (TP + TN) / (TP + TN + FP + FN)$$
- **Precisão (*Precision*):** Mede a proporção de acertos entre todas as instâncias classificadas como insatisfeitas:
$$\text{Precisão} = TP / (TP + FP)$$
- **Revocação (*Recall* / *Sensibilidade*):** Mede a capacidade do modelo em capturar a totalidade de clientes efetivamente insatisfeitos:
$$\text{Recall} = TP / (TP + FN)$$
- **F_1 -Score:** Média harmônica entre Precisão e Revocação, utilizada como métrica principal devido ao desbalanceamento de classes nas avaliações do e-commerce:
$$F_1\text{-Score} = 2 \cdot (\text{Precisão} \cdot \text{Recall}) / (\text{Precisão} + \text{Recall})$$
- **Área sob a Curva ROC (ROC-AUC):** Avaliará a capacidade de discriminação do modelo entre as classes ao variar o limiar de decisão (*threshold*).

5.2 Métricas para o Modelo de Agrupamento / Clustering (Pergunta 2: Impacto do Frete)

Como a tarefa de agrupamento é não supervisionada (não há rótulos de teste), a qualidade dos clusters será avaliada por:

- **Coeficiente de Silhueta (*Silhouette Score*):** Calcula a compacidade intra-cluster e a separabilidade inter-cluster de cada ponto i :
$$s(i) = [b(i) - a(i)] / \max(a(i), b(i))$$
 Onde $a(i)$ é a distância média entre o ponto i e todos os outros pontos do mesmo cluster, e $b(i)$ é a distância média do ponto i ao cluster mais próximo. O resultado varia de -1 a $+1$, sendo valores próximos a $+1$ indicativos de agrupamentos coesos e bem delimitados.
- **Inércia (WCSS):** Utilizada para o Método do Cotovelo na identificação do ponto de retornos decrescentes do número k de clusters.

5.3 Métricas para o Modelo de Séries Temporais e Regressão (Pergunta 3: Sazonalidade de Vendas)

A validação da capacidade de previsão do volume financeiro (GMV) e quantidade de vendas utilizará as seguintes métricas de erro sobre a amostra de teste:

- **Erro Absoluto Médio (MAE):**

$$\text{MAE} = (1 / n) \cdot \sum_{t=1}^n |y_t - \hat{y}_t|$$

- **Raiz do Erro Quadrático Médio (RMSE):** Penaliza erros de maior magnitude com mais severidade:

$$\text{RMSE} = \sqrt{[(1 / n) \cdot \sum_{t=1}^n (y_t - \hat{y}_t)^2]}$$

- **Erro Percentual Absoluto Médio (MAPE):** Expressa a precisão do modelo em termos percentuais relativos ao valor real:

$$\text{MAPE} = (100\% / n) \cdot \sum_{t=1}^n |(y_t - \hat{y}_t) / y_t| \text{ Onde } y_t \text{ representa o valor real observado no período } t \text{ e } \hat{y}_t \text{ o valor projetado pelo modelo.}$$